

Problema de Transporte Logístico Discreto

Diseño y Análisis de Algoritmos

Richard Alejandro Matos Arderí

Abel Ponce González

Abraham Romero Imbert

Facultad de Matemática y Computación
Universidad de La Habana

27 de diciembre de 2025

Resumen

Este informe presenta un estudio completo del problema de *Balanced Multi-Bin Packing with Capacity Constraints*, un problema de optimización combinatoria NP-hard con aplicaciones en logística y distribución de cargas. Se desarrolla la formalización matemática del problema, se demuestra su complejidad computacional mediante reducción desde 3-PARTITION, y se implementan múltiples enfoques algorítmicos incluyendo algoritmos greedy, programación dinámica, branch and bound, y metaheurísticas (Simulated Annealing, Algoritmos Genéticos, Búsqueda Tabú). Se presenta además un análisis experimental comparativo de los algoritmos implementados.

Índice

1. Introducción	4
1.1. Motivación	4
1.2. Objetivos del Proyecto	4
2. Definición Formal del Problema	4
2.1. Notación y Definiciones	4
2.2. Formulación del Problema	5
2.3. Formulación como Programa Lineal Entero (ILP)	5
3. Análisis de Complejidad	6
3.1. Clases de Complejidad y el Problema de Decisión	6
3.2. NP-Compleitud del Problema de Decisión	6
3.3. Cadena de Reducciones: De PARTITION a Nuestro Problema	7
3.3.1. Problema PARTITION (Punto de Partida)	7
3.3.2. Problema 3-PARTITION	7
3.3.3. Reducción 1: PARTITION \leq_p 3-PARTITION	8

3.3.4. Reducción 2: 3-PARTITION \leq_p BALANCED-BIN-PACKING	9
3.4. Implicaciones de la NP-Compleitud	10
3.5. Problema con Capacidades Heterogéneas	10
3.6. Complejidad de los Algoritmos Implementados	10
4. Algoritmos Implementados	11
4.1. Algoritmo de Fuerza Bruta (Búsqueda Exhaustiva)	11
4.1.1. Intuición del Algoritmo	11
4.1.2. Descripción Formal	11
4.1.3. Análisis de Complejidad	12
4.1.4. Demostración de Correctitud	12
4.1.5. Límites Prácticos	13
4.1.6. Verificación de Complejidad	13
4.1.7. Rol del Algoritmo de Fuerza Bruta	14
4.2. Algoritmos Greedy	14
4.2.1. First Fit Decreasing (FFD)	14
4.2.2. LPT Balanced	14
4.3. Branch and Bound	15
4.3.1. Intuición del Algoritmo	15
4.3.2. Descripción Formal	15
4.4. Programación Dinámica	16
4.4.1. Intuición del Algoritmo	16
4.4.2. Esquema SRTBOT	17
4.4.3. Demostración de Correctitud	19
4.4.4. Pseudocódigo Detallado	20
4.4.5. Límites Prácticos y Resultados Empíricos	22
4.4.6. Verificación de Complejidad	22
4.5. Metaheurísticas	23
4.5.1. Simulated Annealing	23
4.5.2. Algoritmo Genético	24
5. Estructura del Proyecto	24
5.1. Arquitectura de Módulos	24
5.2. Estructuras de Datos Principales	25
6. Resultados Experimentales	26
6.1. Configuración Experimental	26
6.2. Análisis de Escalabilidad	26
6.3. Análisis Comparativo con Solución Óptima	26
6.3.1. Metodología	26
6.3.2. Resultados	27
6.3.3. Observaciones	27
6.3.4. Comportamiento por Tipo de Instancia	27
7. Conclusiones	28
7.1. Resumen	28
7.2. Trabajo Futuro	28

A. Manual de Uso	29
A.1. Instalación	29
A.2. Uso Básico	29
A.3. Dashboard	29

1. Introducción

1.1. Motivación

El problema de empaquetamiento balanceado en múltiples contenedores surge en numerosas aplicaciones prácticas de logística y distribución. Considérese el escenario de una empresa de transporte que debe distribuir n paquetes en k vehículos, donde cada vehículo tiene una capacidad máxima de peso y se desea equilibrar la carga de trabajo (medida en valor o tiempo de entrega) entre todos los vehículos.

A diferencia del problema clásico de bin packing que busca minimizar el número de contenedores, nuestro problema tiene un número fijo de contenedores y busca:

1. Respetar las restricciones de capacidad de peso
2. Minimizar el desbalance de valores entre contenedores

1.2. Objetivos del Proyecto

Los objetivos principales de este proyecto son:

- Formalizar matemáticamente el problema
- Demostrar su complejidad computacional
- Implementar y analizar múltiples enfoques algorítmicos
- Desarrollar herramientas de visualización y benchmarking
- Crear un dashboard interactivo para experimentación

2. Definición Formal del Problema

2.1. Notación y Definiciones

Definición 2.1 (Ítem). *Un ítem $i \in I$ se caracteriza por un par (w_i, v_i) donde:*

- $w_i \in \mathbb{R}^+$: *peso del ítem*
- $v_i \in \mathbb{R}^+$: *valor del ítem*

Definición 2.2 (Contenedor (Bin)). *Un contenedor $j \in \{1, \dots, k\}$ tiene una capacidad máxima individual $C_j \in \mathbb{R}^+$. Cada contenedor puede tener una capacidad diferente.*

Definición 2.3 (Asignación). *Una asignación es una función $\sigma : I \rightarrow \{1, \dots, k\}$ que mapea cada ítem a un contenedor.*

Definición 2.4 (Asignación Factible). *Una asignación σ es factible si y solo si:*

$$\forall j \in \{1, \dots, k\} : \sum_{i:\sigma(i)=j} w_i \leq C_j$$

donde C_j es la capacidad específica del contenedor j .

2.2. Formulación del Problema

Entrada:

- Conjunto de ítems $I = \{1, 2, \dots, n\}$
- Peso $w_i > 0$ y valor $v_i \geq 0$ para cada ítem $i \in I$
- Número de contenedores $k \in \mathbb{Z}^+$
- Capacidad individual $C_j > 0$ para cada contenedor $j \in \{1, \dots, k\}$

Variable de Decisión:

$$x_{ij} = \begin{cases} 1 & \text{si el ítem } i \text{ es asignado al contenedor } j \\ 0 & \text{en otro caso} \end{cases}$$

Objetivo: Minimizar el desbalance (diferencia entre valor máximo y mínimo):

$$\min \left(\max_{j \in \{1, \dots, k\}} V_j - \min_{j \in \{1, \dots, k\}} V_j \right)$$

donde $V_j = \sum_{i: \sigma(i)=j} v_i$ es el valor total del contenedor j .

2.3. Formulación como Programa Lineal Entero (ILP)

Para modelar la función objetivo $\min(\max_j V_j - \min_j V_j)$, introducimos dos variables auxiliares:

- z^+ : cota superior del valor máximo entre contenedores
- z^- : cota inferior del valor mínimo entre contenedores

$$\text{minimizar} \quad z^+ - z^- \tag{1}$$

$$\text{sujeto a:} \quad \sum_{j=1}^k x_{ij} = 1 \quad \forall i \in I \tag{2}$$

$$\sum_{i=1}^n w_i \cdot x_{ij} \leq C_j \quad \forall j = 1, \dots, k \tag{3}$$

$$\sum_{i=1}^n v_i \cdot x_{ij} \leq z^+ \quad \forall j = 1, \dots, k \tag{4}$$

$$\sum_{i=1}^n v_i \cdot x_{ij} \geq z^- \quad \forall j = 1, \dots, k \tag{5}$$

$$x_{ij} \in \{0, 1\} \quad \forall i \in I, j = 1, \dots, k \tag{6}$$

$$z^+, z^- \geq 0 \tag{7}$$

Donde:

- (1): Función objetivo que minimiza la diferencia entre cotas

- (2): Cada ítem debe asignarse a exactamente un contenedor
- (3): Restricción de capacidad por peso (cada contenedor j tiene su propia capacidad C_j)
- (4): z^+ es cota superior del valor de cada contenedor, por tanto $z^+ \geq \max_j V_j$
- (5): z^- es cota inferior del valor de cada contenedor, por tanto $z^- \leq \min_j V_j$
- (6): Variables binarias de decisión

Proposición 2.1 (Correctitud de la Formulación). *En el óptimo de la formulación ILP, se cumple $z^+ = \max_j V_j$ y $z^- = \min_j V_j$.*

Demostración. Sea (x^*, z^{+*}, z^{-*}) una solución óptima y sean $V_j^* = \sum_i v_i x_{ij}^*$ los valores de los contenedores.

Para z^+ : Las restricciones (4) implican $z^{+*} \geq V_j^*$ para todo j , es decir, $z^{+*} \geq \max_j V_j^*$. Como minimizamos $z^+ - z^-$, en el óptimo $z^{+*} = \max_j V_j^*$ (de lo contrario podríamos reducir z^+).

Para z^- : Las restricciones (5) implican $z^{-*} \leq V_j^*$ para todo j , es decir, $z^{-*} \leq \min_j V_j^*$. Como minimizamos $z^+ - z^-$, en el óptimo $z^{-*} = \min_j V_j^*$ (de lo contrario podríamos incrementar z^-).

Por tanto, el valor óptimo es $z^{+*} - z^{-*} = \max_j V_j^* - \min_j V_j^*$. □

3. Análisis de Complejidad

3.1. Clases de Complejidad y el Problema de Decisión

Antes de analizar la complejidad de nuestro problema, es fundamental distinguir entre problemas de optimización y problemas de decisión.

Definición 3.1 (Problema de Optimización vs. Decisión). ■ *Problema de Optimización (BALANCED-BIN-PACKING-OPT):*

Dados n ítems con pesos y valores, k bins con capacidades C_1, \dots, C_k , encontrar una asignación factible que minimice la diferencia máxima de valores entre bins.

■ *Problema de Decisión (BALANCED-BIN-PACKING-DEC):*

Dados n ítems con pesos y valores, k bins con capacidades C_1, \dots, C_k , y un umbral B , ¿existe una asignación factible tal que la diferencia máxima de valores entre bins sea $\leq B$?

Proposición 3.1. *Si el problema de decisión BALANCED-BIN-PACKING-DEC está en NP, entonces el problema de optimización BALANCED-BIN-PACKING-OPT está en NPO (problemas de optimización NP).*

3.2. NP-Completitud del Problema de Decisión

Teorema 3.2 (NP-Completitud de BALANCED-BIN-PACKING-DEC). *El problema de decisión BALANCED-BIN-PACKING-DEC es NP-completo.*

Demostración. Demostraremos que BALANCED-BIN-PACKING-DEC \in NP-completo mediante dos pasos:

Paso 1: BALANCED-BIN-PACKING-DEC \in NP

Un certificado para una instancia con respuesta 'sí' es una asignación $\sigma : I \rightarrow \{1, \dots, k\}$. La verificación requiere:

1. Verificar que cada ítem está asignado: $O(n)$
2. Calcular peso total de cada bin: $O(n)$
3. Verificar restricciones de capacidad: $O(k)$
4. Calcular valor total de cada bin: $O(n)$
5. Verificar que $\max_j V_j - \min_j V_j \leq B$: $O(k)$

Total: $O(n + k)$, por lo tanto el certificado es verificable en tiempo polinomial. \square

Paso 2: NP-Hardness mediante reducción desde 3-PARTITION

\square

3.3. Cadena de Reducciones: De PARTITION a Nuestro Problema

Para comprender mejor la dureza del problema, presentamos la cadena de reducciones desde problemas fundamentales:

Cadena de Reducciones Polinomiales:

$$\text{PARTITION} \leq_p \text{3-PARTITION} \leq_p \text{BALANCED-BIN-PACKING}$$

3.3.1. Problema PARTITION (Punto de Partida)

Definición 3.2 (PARTITION). **Entrada:** Conjunto $S = \{a_1, a_2, \dots, a_n\}$ de enteros positivos.

Pregunta: ¿Existe un subconjunto $S' \subseteq S$ tal que $\sum_{a_i \in S'} a_i = \sum_{a_i \in S \setminus S'} a_i = \frac{1}{2} \sum_{a_i \in S} a_i$?

PARTITION es uno de los 21 problemas originales de Karp (1972) demostrados NP-completos.

3.3.2. Problema 3-PARTITION

Definición 3.3 (3-PARTITION). **Entrada:** Conjunto $A = \{a_1, a_2, \dots, a_{3m}\}$ de $3m$ enteros positivos y un entero B tal que:

- $\sum_{i=1}^{3m} a_i = mB$
- $\frac{B}{4} < a_i < \frac{B}{2}$ para todo i

Pregunta: ¿Se puede particionar A en m conjuntos disjuntos A_1, \dots, A_m tal que cada A_i contiene exactamente 3 elementos y $\sum_{a \in A_i} a = B$?

Importancia: 3-PARTITION es fuertemente NP-completo, lo que significa que permanece NP-completo incluso si los números se representan en unaryo (Garey & Johnson, 1979).

3.3.3. Reducción 1: PARTITION \leq_p 3-PARTITION

Lema 3.3 (Reducción desde PARTITION). *PARTITION se reduce polinomialmente a 3-PARTITION.*

Demostración. Dada una instancia de PARTITION con conjunto $S = \{a_1, \dots, a_n\}$ donde $\sum_{i=1}^n a_i = 2T$, construimos una instancia de 3-PARTITION:

Construcción:

Sea $M = 4T + 1$ un valor suficientemente grande. Construimos $3n$ elementos:

- Para cada $a_i \in S$, creamos tres elementos: $b_{i,1} = M + a_i$, $b_{i,2} = 2M$, $b_{i,3} = 2M - a_i$

Definimos:

- Número de grupos: $m = n$
- Objetivo por grupo: $B = 5M$

Verificación de restricciones de 3-PARTITION:

- Suma total: $\sum_{i=1}^n (b_{i,1} + b_{i,2} + b_{i,3}) = \sum_{i=1}^n ((M + a_i) + 2M + (2M - a_i)) = 5Mn = mB$ ✓
- Cada elemento satisface $\frac{B}{4} < b_{i,j} < \frac{B}{2}$:
 - $\frac{5M}{4} < M + a_i < \frac{5M}{2}$ se cumple porque $a_i < T < M$ y $M > 0$
 - $\frac{5M}{4} < 2M < \frac{5M}{2}$ se cumple claramente
 - $\frac{5M}{4} < 2M - a_i < \frac{5M}{2}$ se cumple porque $a_i < T < M$

Correctitud (\Rightarrow):

Si existe una partición $S', S \setminus S'$ de PARTITION con $\sum_{a_i \in S'} a_i = T$:

Para cada i , agrupamos $\{b_{i,1}, b_{i,2}, b_{i,3}\}$ en un conjunto A_i . Cada grupo suma exactamente $(M + a_i) + 2M + (2M - a_i) = 5M = B$. Esta es una 3-partición válida.

Correctitud (\Leftarrow):

Si existe una 3-partición válida, observemos que:

- Cada grupo debe sumar exactamente $B = 5M$
- Por las restricciones de tamaño, cada grupo tiene exactamente 3 elementos
- El único elemento de valor $2M$ en cada tripleta $(b_{i,1}, b_{i,2}, b_{i,3})$ es $b_{i,2}$
- Para que un grupo sume $5M$, si contiene $b_{i,2} = 2M$, los otros dos elementos deben sumar $3M$
- Los únicos pares que suman $3M$ son de la forma $(b_{i,1}, b_{i,3}) = (M + a_i, 2M - a_i)$ o $(b_{j,1}, b_{k,3})$ con $a_j + a_k = M$

Dado que $M > 2T$ y cada $a_i \leq T$, no existen a_j, a_k tales que $a_j + a_k = M$. Por tanto, cada grupo debe contener exactamente $\{b_{i,1}, b_{i,2}, b_{i,3}\}$ para algún i .

Esto implica que la 3-partición corresponde a una partición válida del conjunto original S . \square \square

3.3.4. Reducción 2: 3-PARTITION \leq_p BALANCED-BIN-PACKING

Lema 3.4 (Reducción desde 3-PARTITION). *3-PARTITION se reduce polinomialmente a BALANCED-BIN-PACKING-DEC.*

Demostración. Dada una instancia de 3-PARTITION con elementos $\{a_1, \dots, a_{3m}\}$ y objetivo B , construimos una instancia de BALANCED-BIN-PACKING-DEC:

Construcción:

1. Para cada elemento a_i , creamos un ítem con:
 - Peso: $w_i = a_i$
 - Valor: $v_i = a_i$ (peso y valor coinciden)
2. Número de bins: $k = m$
3. Capacidad de cada bin: $C_j = B$ para $j = 1, \dots, m$ (capacidades uniformes)
4. Umbral de balance: $\beta = 0$ (buscamos balance perfecto)

Correctitud (\Rightarrow):

Supongamos que existe una 3-partición válida A_1, \dots, A_m de los elementos originales. Construimos una asignación σ para BALANCED-BIN-PACKING:

- Para cada conjunto A_j en la 3-partición, asignamos los ítems correspondientes al bin j
- Cada bin j contiene exactamente 3 ítems con peso total B
- Por construcción ($v_i = w_i$), el valor total de cada bin es también B
- La diferencia máxima de valores es: $\max_j V_j - \min_j V_j = B - B = 0 \leq \beta$

Por lo tanto, la asignación es factible y satisface el umbral de balance.

Correctitud (\Leftarrow):

Supongamos que existe una asignación factible σ para BALANCED-BIN-PACKING con diferencia ≤ 0 .

Esto implica que todos los bins tienen el mismo valor total. Como:

- Suma total de valores: $\sum_{i=1}^{3m} v_i = \sum_{i=1}^{3m} a_i = mB$
- Número de bins: $k = m$
- Todos los bins tienen igual valor

Cada bin debe tener valor exactamente $\frac{mB}{m} = B$.

Dado que $v_i = w_i$ y el bin tiene capacidad B , cada bin también tiene peso total B (está completamente lleno).

Las restricciones $\frac{B}{4} < a_i < \frac{B}{2}$ garantizan que:

- Ningún bin puede tener menos de 3 elementos (ya que $3 \times \frac{B}{4} > \frac{3B}{4}$ pero necesitamos llegar a B)
- Ningún bin puede tener más de 3 elementos (ya que $4 \times \frac{B}{4} = B$ pero cada elemento es $> \frac{B}{4}$)

Por lo tanto, cada bin contiene exactamente 3 elementos que suman B , constituyendo una 3-partición válida. \square

3.4. Implicaciones de la NP-Compleitud

Corolario 3.5. *El problema de optimización BALANCED-BIN-PACKING-OPT es NP-hard.*

Demostración. Si existiera un algoritmo polinomial para BALANCED-BIN-PACKING-OPT, podríamos resolver BALANCED-BIN-PACKING-DEC en tiempo polinomial:

1. Ejecutar el algoritmo de optimización
2. Comparar el resultado con B
3. Responder 'sí' si resultado $\leq B$, 'no' en caso contrario

Como BALANCED-BIN-PACKING-DEC es NP-completo, esto implicaría $P = NP$.

□

□

3.5. Problema con Capacidades Heterogéneas

Proposición 3.6. *El problema BALANCED-BIN-PACKING con capacidades heterogéneas (diferentes C_j por bin) es al menos tan difícil como el caso con capacidades uniformes.*

Demostración. El caso uniforme es una instancia particular del caso heterogéneo (cuando $C_1 = C_2 = \dots = C_k$).

Si existiera un algoritmo polinomial para el caso heterogéneo, también resolvería el caso uniforme en tiempo polinomial, lo cual contradice la NP-hardness del caso uniforme (asumiendo $P \neq NP$). □

3.6. Complejidad de los Algoritmos Implementados

Cuadro 1: Complejidad temporal y espacial de los algoritmos implementados

Algoritmo	Tiempo	Espacio
First Fit Decreasing (FFD)	$O(n \log n + n \cdot k)$	$O(n + k)$
Best Fit Decreasing (BFD)	$O(n \log n + n \cdot k)$	$O(n + k)$
Worst Fit Decreasing (WFD)	$O(n \log n + n \log k)$	$O(n + k)$
LPT Balanced	$O(n \log n + n \log k)$	$O(n + k)$
Programación Dinámica	$O(k^2 \cdot 3^n)$	$O(k \cdot 2^n)$
Branch and Bound	$O(k^n)$ peor caso	$O(n \cdot k)$
Simulated Annealing	$O(I \cdot n)$	$O(n)$
Genetic Algorithm	$O(G \cdot P \cdot n)$	$O(P \cdot n)$
Tabu Search	$O(I \cdot N)$	$O(n + T)$

Donde:

- n : número de ítems
- k : número de contenedores (bins)
- I : número de iteraciones

- G : número de generaciones
- P : tamaño de población
- N : tamaño del vecindario
- T : tamaño de la lista tabú

4. Algoritmos Implementados

4.1. Algoritmo de Fuerza Bruta (Búsqueda Exhaustiva)

4.1.1. Intuición del Algoritmo

El algoritmo de fuerza bruta responde a la pregunta más fundamental: “*¿Cuál es la mejor solución posible?*” Lo hace de la manera más directa imaginable: **probando todas las opciones**.

Para cada ítem, tenemos k opciones (asignarlo al contenedor 1, 2, ..., o k). Con n ítems, esto genera k^n combinaciones posibles. Probamos cada una, verificamos si es válida (respetá las capacidades), y nos quedamos con la mejor.

Analogía: Imagina que tienes 5 cajas de diferente peso y 3 camiones con límites de carga distintos. La fuerza bruta es como escribir todas las formas posibles de asignar las cajas: “caja 1 al camión 1, caja 2 al camión 1, ...” hasta “caja 1 al camión 3, caja 2 al camión 3, ...” (en total $3^5 = 243$ combinaciones). Luego, para cada combinación:

1. ¿Algún camión excede su límite de carga? Si sí, descarta esta opción.
2. Si no, calcula qué tan “balanceada” quedó la carga.
3. Guarda la mejor solución encontrada hasta ahora.

¿Por qué es útil a pesar de ser lento? La fuerza bruta **garantiza** encontrar el óptimo. Esto es invaluable para:

- Validar que otros algoritmos funcionan correctamente
- Medir qué tan lejos están las heurísticas del óptimo
- Resolver instancias pequeñas donde la optimalidad es crítica

4.1.2. Descripción Formal

Para un problema con n ítems y k contenedores, el algoritmo explora las k^n posibles asignaciones completas. Cada ítem i puede asignarse a cualquiera de los k contenedores, por lo que el espacio de búsqueda crece exponencialmente.

Algorithm 1 Búsqueda Exhaustiva (Fuerza Bruta)

```
1: procedure BRUTEFORCE( $items, k, C_1, \dots, C_k$ )
2:    $best\_diff \leftarrow \infty$ 
3:    $best\_assignment \leftarrow \text{null}$ 
4:   for  $assignment \in \{0, 1, \dots, k - 1\}^n$  do       $\triangleright$  Enumerar todas las  $k^n$  asignaciones
5:      $bins \leftarrow \text{Crear } k \text{ contenedores vacíos}$ 
6:      $valid \leftarrow True$ 
7:     for  $i \leftarrow 0$  to  $n - 1$  do
8:        $j \leftarrow assignment[i]$                        $\triangleright$  Contenedor asignado al ítem  $i$ 
9:       if  $\text{weight}(bins[j]) + items[i].weight > C_j$  then
10:         $valid \leftarrow False$ 
11:        break
12:      end if
13:       $bins[j].add(items[i])$ 
14:    end for
15:    if  $valid$  then
16:       $values \leftarrow [\text{value}(bin) \text{ for } bin \in bins]$ 
17:       $diff \leftarrow \max(values) - \min(values)$ 
18:      if  $diff < best\_diff$  then
19:         $best\_diff \leftarrow diff$ 
20:         $best\_assignment \leftarrow assignment$ 
21:      end if
22:    end if
23:  end for
24:  return  $best\_assignment, best\_diff$ 
25: end procedure
```

4.1.3. Análisis de Complejidad

Teorema 4.1 (Complejidad del Algoritmo de Fuerza Bruta). *El algoritmo de búsqueda exhaustiva tiene:*

- **Complejidad temporal:** $O(k^n \cdot n)$
- **Complejidad espacial:** $O(n + k)$

Demostración. **Tiempo:** Existen k^n asignaciones posibles. Para cada asignación, se verifica la factibilidad y se calcula el objetivo, ambas operaciones en $O(n)$. Total: $O(k^n \cdot n)$.

Espacio: Se almacena la asignación actual ($O(n)$), la mejor asignación ($O(n)$), y los valores acumulados por contenedor ($O(k)$). Total: $O(n + k)$. \square

4.1.4. Demostración de Correctitud

Teorema 4.2 (Correctitud del Algoritmo de Fuerza Bruta). *El algoritmo de búsqueda exhaustiva encuentra una solución óptima factible si existe, o reporta infactibilidad en caso contrario.*

Demostración. Sea \mathcal{A} el conjunto de todas las asignaciones posibles, donde una asignación es una función $\sigma : \{1, \dots, n\} \rightarrow \{1, \dots, k\}$ que mapea cada ítem a un contenedor. Claramente $|\mathcal{A}| = k^n$.

Sea $\mathcal{F} \subseteq \mathcal{A}$ el conjunto de asignaciones factibles (aquellas que respetan todas las restricciones de capacidad).

El algoritmo:

1. **Enumera** todos los elementos de \mathcal{A} (completitud)
2. Para cada $\sigma \in \mathcal{A}$, **verifica** si $\sigma \in \mathcal{F}$ (factibilidad)
3. Para cada $\sigma \in \mathcal{F}$, **calcula** $f(\sigma) = \max_j V_j(\sigma) - \min_j V_j(\sigma)$ (evaluación)
4. **Retorna** $\arg \min_{\sigma \in \mathcal{F}} f(\sigma)$ (selección del óptimo)

Como el algoritmo evalúa *todas* las asignaciones factibles y selecciona la de mínimo valor objetivo, necesariamente encuentra el óptimo global si $\mathcal{F} \neq \emptyset$. \square

Corolario 4.3. *El algoritmo de fuerza bruta es exacto: para cualquier instancia con solución factible, el valor returnedo es igual al óptimo global z^* .*

4.1.5. Límites Prácticos

Mediante análisis empírico se determinaron los tamaños máximos de instancia resolubles en tiempos razonables:

Cuadro 2: Tamaño máximo de instancia resoluble por fuerza bruta

Contenedores (k)	Máx n (1s)	Máx n (10s)	Máx n (60s)
$k = 2$	14	14	14
$k = 3$	11	13	14
$k = 4$	8	10	11
$k = 5$	7	9	10

La Tabla 2 confirma la complejidad $O(k^n)$: al aumentar k , el tamaño máximo resoluble disminuye proporcionalmente. Por ejemplo, con $k = 2$ y $n = 14$, el espacio de búsqueda es $2^{14} = 16,384$ asignaciones, mientras que con $k = 4$ y $n = 10$ es $4^{10} \approx 1,048,576$ asignaciones.

4.1.6. Verificación de Complejidad

Se observó que para $k = 2$, el tiempo aproximadamente se duplica por cada incremento en n , confirmando el comportamiento $O(2^n \cdot n) \approx O(2^n)$ para k fijo:

n	Tiempo (segundos)
10	0.0051
11	0.0101 ($\times 2,0$)
12	0.0204 ($\times 2,0$)
13	0.0401 ($\times 2,0$)
14	0.0858 ($\times 2,1$)

4.1.7. Rol del Algoritmo de Fuerza Bruta

El algoritmo de fuerza bruta sirve tres propósitos fundamentales:

1. **Verificación de correctitud:** Permite validar que las soluciones heurísticas sean factibles comparándolas con el óptimo garantizado.
2. **Medición de calidad:** Establece la línea base para calcular el *gap* de optimalidad:

$$\text{Gap(\%)} = \frac{\text{Heurístico} - \text{Óptimo}}{\text{Óptimo}} \times 100$$

3. **Generación de instancias de prueba:** Para instancias pequeñas, permite conocer el óptimo verdadero y así diseñar tests unitarios.

4.2. Algoritmos Greedy

4.2.1. First Fit Decreasing (FFD)

El algoritmo FFD ordena los ítems por peso decreciente y asigna cada ítem al primer contenedor que tiene capacidad suficiente.

Algorithm 2 First Fit Decreasing

```
1: procedure FFD(items, k,  $C_1, \dots, C_k$ )
2:   sorted_items  $\leftarrow$  sort(items, key = weight, desc = True)
3:   bins  $\leftarrow$  [ ]  $\times k$                                  $\triangleright$  Crear k bins con capacidades  $C_j$ 
4:   for item  $\in$  sorted_items do
5:     for j  $\leftarrow 1$  to k do
6:       if weight(bins[j]) + item.weight  $\leq C_j$  then
7:         bins[j].add(item)
8:         break
9:       end if
10:      end for
11:    end for
12:    return bins
13: end procedure
```

4.2.2. LPT Balanced

El algoritmo Longest Processing Time (LPT) adaptado para balanceo asigna cada ítem al contenedor con menor carga actual, respetando las capacidades individuales.

Algorithm 3 LPT Balanced

```
1: procedure LPT(items, k,  $C_1, \dots, C_k$ )
2:   sorted_items  $\leftarrow$  sort(items, key = value, desc = True)
3:   bins  $\leftarrow$  [ ]  $\times$  k                                 $\triangleright$  Bins con capacidades individuales
4:   for item  $\in$  sorted_items do
5:      $j^* \leftarrow \arg \min_{j: \text{weight}(bins[j]) + item.weight \leq C_j} \text{value}(bins[j])$ 
6:     bins[j*].add(item)
7:   end for
8:   return bins
9: end procedure
```

4.3. Branch and Bound

4.3.1. Intuición del Algoritmo

Branch and Bound es una versión “inteligente” de la fuerza bruta que evita explorar soluciones que sabemos de antemano que no pueden ser óptimas.

En lugar de probar todas las k^n asignaciones, construimos el árbol de decisiones paso a paso. Antes de expandir una rama, calculamos una cota inferior de lo mejor que podría lograr esa rama. Si la cota ya es peor que la mejor solución encontrada, podamos la rama entera.

Analogía: Imagina que buscas el vuelo más barato de A a B con escalas. Si ya encontraste un vuelo de \$500, y un vuelo parcial de A a C ya cuesta \$600, no tiene sentido buscar vuelos de C a B: cualquier ruta por C costará más de \$500.

Componentes clave:

1. **Branching (Ramificación):** Decidir cómo dividir el problema en subproblemas más pequeños (e.g., “el ítem 1 va al bin 1” vs “el ítem 1 va al bin 2”).
2. **Bounding (Acotación):** Calcular una cota inferior optimista del mejor valor alcanzable desde el estado actual.
3. **Pruning (Poda):** Descartar ramas cuya cota inferior supera la mejor solución conocida.

¿Cuándo es efectivo? B&B funciona bien cuando:

- Las cotas son ajustadas (cercañas al valor real)
- Muchas ramas pueden podarse temprano
- La mejor solución se encuentra rápido (mejora el umbral de poda)

4.3.2. Descripción Formal

El algoritmo de Branch and Bound explora sistemáticamente el espacio de soluciones utilizando cotas para podar ramas no prometedoras.

Algorithm 4 Branch and Bound

```
1: procedure BRANCHANDBOUND( $items, k, C_1, \dots, C_k$ )
2:    $best \leftarrow \infty$ 
3:    $best\_solution \leftarrow \text{null}$ 
4:    $queue \leftarrow \{(\emptyset, items)\}$                                  $\triangleright$  (asignación parcial, ítems restantes)
5:   while  $queue \neq \emptyset$  do
6:      $(partial, remaining) \leftarrow queue.pop()$ 
7:     if  $remaining = \emptyset$  then
8:        $obj \leftarrow \text{objective}(partial)$ 
9:       if  $obj < best$  then
10:         $best \leftarrow obj$ 
11:         $best\_solution \leftarrow partial$ 
12:      end if
13:    else
14:       $item \leftarrow remaining[0]$ 
15:      for  $j \leftarrow 1$  to  $k$  do
16:        if  $\text{weight}(partial[j]) + item.weight \leq C_j$  then
17:           $new\_partial \leftarrow \text{assign}(partial, j, item)$ 
18:           $lb \leftarrow \text{lower\_bound}(new\_partial, remaining[1 :])$ 
19:          if  $lb < best$  then                                 $\triangleright$  Pruning
20:             $queue.push((new\_partial, remaining[1 :]))$ 
21:          end if
22:        end if
23:      end for
24:    end if
25:  end while
26:  return  $best\_solution$ 
27: end procedure
```

4.4. Programación Dinámica

4.4.1. Intuición del Algoritmo

La programación dinámica resuelve el problema de forma **óptima** para instancias pequeñas mediante una estrategia de “divide y vencerás con memoización”. La idea fundamental es:

Para encontrar la mejor asignación de n ítems a k contenedores, construimos la solución bin por bin: primero decidimos qué ítems van al contenedor 1, luego con los restantes decidimos qué va al contenedor 2, y así sucesivamente hasta el contenedor k .

¿Por qué funciona? El problema exhibe **subestructura óptima**: si tenemos la mejor forma de asignar un subconjunto de ítems a $j - 1$ contenedores, entonces para encontrar la mejor asignación a j contenedores solo necesitamos considerar cómo distribuir los ítems restantes en el nuevo contenedor.

Analogía: Imagina que tienes 10 libros y 3 estantes con diferentes capacidades de peso. En lugar de probar las 3^{10} formas de distribuir los libros, puedes:

1. Considerar todas las formas válidas de llenar el estante 1
2. Para cada forma, considerar todas las formas válidas de llenar el estante 2 con los libros restantes
3. Finalmente poner los libros sobrantes en el estante 3

La clave es que si ya encontraste la mejor distribución para los estantes 1 y 2 dado un conjunto de libros asignados, no necesitas recalcular eso cada vez.

4.4.2. Esquema SRTBOT

Presentamos la formulación completa utilizando el esquema SRTBOT (Subproblemas, Relación de recurrencia, Topología, Base, Original, Tiempo):

S - Subproblemas:

Definimos el subproblema $DP[j][mask]$ que representa la mejor configuración para asignar los ítems indicados por $mask$ a los primeros j contenedores, respetando las capacidades **heterogéneas** C_1, \dots, C_j .

Formalmente:

- $mask \in \{0, 1, \dots, 2^n - 1\}$: subconjunto de ítems asignados (bitmask donde el bit i indica si el ítem i está asignado)
- $j \in \{1, \dots, k\}$: número de contenedores utilizados
- $DP[j][mask] = (\vec{V}, assignment)$ donde:
 - $\vec{V} = (V_1, V_2, \dots, V_j)$: tupla de valores de cada contenedor
 - $assignment$: lista de conjuntos de ítems por contenedor

Nota crítica sobre capacidades heterogéneas: Almacenamos los valores de *todos* los contenedores (no solo max/min) porque con capacidades diferentes C_j , el contenedor óptimo para un subconjunto depende de cuál contenedor específico se está llenando, no solo del valor resultante.

Número de subproblemas: $O(k \cdot 2^n)$

R - Relación de Recurrencia:

Para transicionar de $j-1$ a j contenedores, para cada estado previo $DP[j-1][mask_{prev}]$, consideramos asignar un subconjunto S de los ítems restantes al contenedor j :

$$DP[j][mask_{prev} \cup S] = \arg \min_{\substack{S \subseteq remaining \\ S \in Factible_j}} \left\{ \max(\vec{V} \oplus V(S)) - \min(\vec{V} \oplus V(S)) \right\}$$

donde:

- $remaining = (\text{full_mask}) \oplus mask_{prev}$: ítems aún no asignados
- $Factible_j = \{S : \sum_{i \in S} w_i \leq C_j\}$: subconjuntos que caben en el contenedor j (con capacidad C_j)
- $V(S) = \sum_{i \in S} v_i$: valor total del subconjunto S
- $\vec{V} \oplus V(S)$: concatenación del valor $V(S)$ a la tupla de valores

Manejo de capacidades heterogéneas: La clave es que $Factible_j$ se calcula *independientemente* para cada contenedor j usando su capacidad específica C_j . Esto garantiza que la restricción de peso se respete correctamente incluso cuando $C_1 \neq C_2 \neq \dots \neq C_k$.

T - Topología (Orden de Resolución):

Los subproblemas se resuelven en el siguiente orden:

1. **Pre-computación:** Para cada $j \in \{1, \dots, k\}$, calcular $Factible_j$ independientemente usando C_j
2. **Ordenar por bins:** $j = 1, 2, \dots, k$
3. **Para cada j :** Iterar sobre todas las máscaras $mask_{prev}$ válidas en $DP[j-1]$, y para cada una, iterar sobre todos los subconjuntos de *remaining*

Este orden garantiza que al calcular $DP[j][mask]$, todos los estados $DP[j-1][mask']$ con $mask' \subset mask$ ya están calculados.

B - Casos Base:

- $DP[1][S] = ((V(S)), [S])$ para todo $S \in Factible_1$

Con un solo contenedor, la tupla de valores tiene un único elemento. La diferencia max-min es trivialmente 0.

- $DP[1][\emptyset] = ((0), [\emptyset])$ incluye el conjunto vacío (valor 0).

O - Problema Original:

El problema original corresponde a:

$$DP[k][full_mask] \quad \text{donde} \quad full_mask = 2^n - 1$$

El valor objetivo óptimo es:

$$z^* = \max(\vec{V}^*) - \min(\vec{V}^*)$$

donde $\vec{V}^* = DP[k][full_mask]$. \vec{V} es la tupla de valores de la asignación óptima.

T - Tiempo de Ejecución:

- **Pre-computación de subconjuntos factibles:**

$$O(k \cdot 2^n \cdot n)$$

Para cada contenedor j , evaluamos 2^n subconjuntos. Para cada subconjunto, calculamos su peso y valor total iterando sobre los n bits de la máscara.

Llenado de tabla DP:

Número de iteraciones: Para cada nivel j , iteramos sobre todos los estados en $DP[j-1]$ y para cada uno, sobre los subconjuntos de *remaining*. El número total de pares $(mask_{prev}, S)$ considerados es:

$$\sum_{j=2}^k \sum_{mask} 2^{n-|mask|} = k \cdot \sum_{m=0}^n \binom{n}{m} \cdot 2^{n-m} = k \cdot (1+2)^n = k \cdot 3^n$$

(Por el teorema del binomio: $(a+b)^n = \sum_{m=0}^n \binom{n}{m} a^m b^{n-m}$ con $a=1, b=2$)

Costo por iteración: Para cada par $(mask_{prev}, S)$, debemos:

1. Verificar $S \in Factible_j$: $O(1)$ (lookup en hash table pre-computada)
2. Obtener $V(S)$: $O(1)$ (pre-computado)
3. Concatenar $\vec{V} \oplus V(S)$: $O(j) \leq O(k)$ para crear la nueva tupla de valores
4. Calcular $\max(\vec{V}')$ y $\min(\vec{V}')$: $O(j) \leq O(k)$ sobre la tupla de j elementos

Por tanto, cada iteración cuesta $O(k)$, y el costo total del llenado es:

$$O(k \cdot 3^n) \times O(k) = O(k^2 \cdot 3^n)$$

- **Espacio:** $O(k \cdot 2^n)$ para la tabla DP (a lo sumo 2^n máscaras por nivel, k niveles, y cada estado almacena una tupla de $O(k)$ valores)
- **Complejidad Total:**

$O(k^2 \cdot 3^n)$

tiempo, $O(k \cdot 2^n)$ espacio

4.4.3. Demostración de Correctitud

Teorema 4.4 (Correctitud del Algoritmo DP). *El algoritmo de programación dinámica encuentra la solución óptima al problema de Balanced Multi-Bin Packing con capacidades heterogéneas.*

Demostración. La demostración procede por inducción sobre el número de contenedores j .

Caso base ($j = 1$): Con un solo contenedor, el algoritmo enumera todos los subconjuntos de ítems que caben en C_1 y almacena sus valores. Dado que no hay elección entre contenedores, la diferencia max-min es trivialmente 0 para cualquier subconjunto válido. ✓

Hipótesis inductiva: Supongamos que para cualquier $j' < j$ y cualquier máscara $mask$, $DP[j'][mask]$ contiene la asignación óptima de los ítems en $mask$ a los primeros j' contenedores.

Paso inductivo ($j-1 \rightarrow j$): Sea $OPT[j][mask]$ la solución óptima real. Esta solución asigna:

- Un subconjunto S^* de ítems al contenedor j
- Los ítems $mask \setminus S^*$ a los contenedores $1, \dots, j-1$

Por la hipótesis inductiva, $DP[j-1][mask \setminus S^*]$ contiene la mejor asignación para los primeros $j-1$ contenedores. El algoritmo considera *todos* los subconjuntos $S \subseteq remaining$ que son factibles para el contenedor j (i.e., $\sum_{i \in S} w_i \leq C_j$), incluyendo S^* .

Por tanto, el algoritmo encuentra S^* (o un S equivalente) y construye $DP[j][mask]$ con valor $\leq OPT[j][mask]$.

Como OPT es óptimo, tenemos $DP[j][mask] = OPT[j][mask]$. ✓

Conclusión: Para $j = k$ y $mask = full_mask$, el algoritmo encuentra $DP[k][full_mask] = OPT$, la solución óptima global. □

4.4.4. Pseudocódigo Detallado

El siguiente algoritmo implementa la estrategia DP descrita en el esquema SRTBOT:

Algorithm 5 Programación Dinámica para Multi-Bin Balancing con Capacidades Heterogéneas

```

1: procedure DYNAMICPROGRAMMING(items, k,  $C_1, \dots, C_k$ )
2:    $n \leftarrow |\text{items}|$ 
3:    $\text{feasible}[j] \leftarrow \{\}$  para  $j = 1, \dots, k$ 
   ▷ Fase 1: Pre-computar subconjuntos factibles para cada bin
4:   for  $j \leftarrow 1$  to k do
5:     for mask  $\leftarrow 0$  to  $2^n - 1$  do
6:        $\text{total\_weight} \leftarrow 0, \text{total\_value} \leftarrow 0$ 
7:       for  $i \leftarrow 0$  to  $n - 1$  do
8:         if mask $\&(1 \ll i)$  then                                ▷ Bit i activo en máscara
9:            $\text{total\_weight} \leftarrow \text{total\_weight} + \text{items}[i].\text{weight}$ 
10:           $\text{total\_value} \leftarrow \text{total\_value} + \text{items}[i].\text{value}$ 
11:        end if
12:      end for
13:      if  $\text{total\_weight} \leq C_j$  then                      ▷ Usar capacidad específica  $C_j$ 
14:         $\text{feasible}[j][\text{mask}] \leftarrow (\text{total\_weight}, \text{total\_value})$ 
15:      end if
16:    end for
17:  end for                                              ▷ Fase 2: Caso base - primer contenedor
18:   $dp[1] \leftarrow \{\}$ 
19:  for mask  $\in \text{feasible}[1]$  do
20:     $v \leftarrow \text{feasible}[1][\text{mask}].\text{value}$ 
21:     $dp[1][\text{mask}] \leftarrow ((v), [\text{mask}])$                 ▷ Tupla con un valor
22:  end for                                              ▷ Fase 3: Transiciones DP - agregar contenedores uno a uno
23:  for  $j \leftarrow 2$  to k do
24:     $dp[j] \leftarrow \{\}$ 
25:    for prev_mask  $\in dp[j - 1]$  do
26:       $(\text{prev\_values}, \text{prev\_assign}) \leftarrow dp[j - 1][\text{prev\_mask}]$ 
27:       $\text{remaining} \leftarrow (2^n - 1) \oplus \text{prev\_mask}$             ▷ Ítems no asignados
28:      for subset  $\in \text{subsets}(\text{remaining}) \cap \text{feasible}[j]$  do
29:         $\text{new\_mask} \leftarrow \text{prev\_mask} \mid \text{subset}$ 
30:         $\text{new\_value} \leftarrow \text{feasible}[j][\text{subset}].\text{value}$ 
31:         $\text{new\_values} \leftarrow \text{prev\_values} \oplus (\text{new\_value})$           ▷ Concatenar
32:         $\text{new\_diff} \leftarrow \max(\text{new\_values}) - \min(\text{new\_values})$ 
33:        if  $\text{new\_mask} \notin dp[j]$  or  $\text{new\_diff} < dp[j][\text{new\_mask}].\text{diff}$  then
34:           $dp[j][\text{new\_mask}] \leftarrow (\text{new\_values}, \text{prev\_assign} + [\text{subset}])$ 
35:        end if
36:      end for
37:    end for
38:  end for                                              ▷ Fase 4: Extraer solución óptima
39:   $full\_mask \leftarrow 2^n - 1$ 
40:  if  $full\_mask \in dp[k]$  then
41:    return  $dp[k][full\_mask].\text{assignment}$ 
42:  else
43:    return INFEASIBLE
44:  end if
45: end procedure

```

Optimizaciones Implementadas:

1. **Poda de estados dominados:** Si dos estados tienen la misma máscara pero diferentes valores, solo conservamos el de menor diferencia max-min.
2. **Límite de tamaño:** Para instancias con $n > 15$, se usa un fallback a algoritmos greedy.
3. **Timeout:** Se verifica periódicamente el tiempo transcurrido para evitar bloqueos en instancias difíciles.

4.4.5. Límites Prácticos y Resultados Empíricos

Mediante análisis empírico se midieron los tiempos de ejecución reales del algoritmo de programación dinámica:

Cuadro 3: Tiempos de ejecución de Programación Dinámica (segundos)

n	$k = 2$	$k = 3$	$k = 4$	$k = 5$
6	0.002	0.003	0.003	0.003
7	0.006	0.006	0.008	0.009
8	0.012	0.019	0.026	0.028
9	0.037	0.059	0.066	0.066
10	0.096	0.178	0.214	—
11	0.297	0.511	—	—
12	0.884	1.436	—	—
13	2.657	4.669	—	—
14	7.996	16.19	—	—
15	29.18	—	—	—

Cuadro 4: Tamaño máximo de instancia resoluble por DP

Contenedores (k)	Máx n (1s)	Máx n (10s)	Máx n (60s)
$k = 2$	12	14	15
$k = 3$	11	13	14
$k = 4$	10	12	13
$k = 5$	9	11	12

4.4.6. Verificación de Complejidad

Los tiempos empíricos confirman la complejidad teórica $O(k^2 \cdot 3^n)$. Para k fijo, el tiempo debe triplicarse aproximadamente por cada incremento en n :

n	Tiempo ($k = 2$)	Factor
10	0.096 s	—
11	0.297 s	$\times 3,1$
12	0.884 s	$\times 3,0$
13	2.657 s	$\times 3,0$
14	7.996 s	$\times 3,0$
15	29.18 s	$\times 3,6$

El factor de crecimiento cercano a 3 confirma el comportamiento $O(3^n)$ para k fijo. La ligera variación se debe al overhead de Python y las operaciones de hash en los diccionarios.

4.5. Metaheurísticas

4.5.1. Simulated Annealing

Algorithm 6 Simulated Annealing

```

1: procedure SA(problem,  $T_0$ ,  $\alpha$ , max_iter)
2:   current  $\leftarrow$  initial_solution(problem)
3:   best  $\leftarrow$  current
4:    $T \leftarrow T_0$ 
5:   for  $i \leftarrow 1$  to max_iter do
6:     neighbor  $\leftarrow$  generate_neighbor(current)
7:      $\Delta \leftarrow f(\text{neighbor}) - f(\text{current})$ 
8:     if  $\Delta < 0$  or random()  $< e^{-\Delta/T}$  then
9:       current  $\leftarrow$  neighbor
10:      if  $f(\text{current}) < f(\text{best})$  then
11:        best  $\leftarrow$  current
12:      end if
13:    end if
14:     $T \leftarrow \alpha \cdot T$                                  $\triangleright$  Enfriamiento
15:   end for
16:   return best
17: end procedure

```

4.5.2. Algoritmo Genético

Algorithm 7 Algoritmo Genético

```
1: procedure GA(problem, pop_size, generations, pc, pm)
2:   population  $\leftarrow$  initialize_population(pop_size)
3:   for g  $\leftarrow$  1 to generations do
4:     fitness  $\leftarrow$  evaluate(population)
5:     new_pop  $\leftarrow$   $\emptyset$ 
6:     while  $|new\_pop| < pop\_size$  do
7:       parent1, parent2  $\leftarrow$  tournament_select(population, fitness)
8:       if random()  $< p_c$  then
9:         child1, child2  $\leftarrow$  crossover(parent1, parent2)
10:      else
11:        child1, child2  $\leftarrow$  parent1, parent2
12:      end if
13:      if random()  $< p_m$  then
14:        child1  $\leftarrow$  mutate(child1)
15:        child2  $\leftarrow$  mutate(child2)
16:      end if
17:      new_pop  $\leftarrow$  new_pop  $\cup \{child_1, child_2\}$ 
18:    end while
19:    population  $\leftarrow$  new_pop
20:  end for
21:  return best(population)
22: end procedure
```

5. Estructura del Proyecto

5.1. Arquitectura de Módulos

El proyecto está organizado en los siguientes módulos principales:

```
discrete_logistics/
++ core/
|  +- problem.py          # Estructuras de datos
|  +- instance_generator.py
++ algorithms/
|  +- base.py             # Clase abstracta Algorithm
|  +- greedy.py            # FFD, BFD, WFD, LPT
|  +- dynamic_programming.py
|  +- branch_and_bound.py
|  +- metaheuristics.py   # SA, GA, Tabu
|  +- approximation.py
++ visualizations/
|  +- plots.py              # Graficos estaticos
|  +- animations.py         # Animaciones Manim/Plotly
|  +- interactive.py        # Componentes interactivos
```

```

+-- theory/
|   +-- formalization.py
|   +-- complexity.py
|   +-- pseudocode.py
+-- benchmarks/
|   +-- runner.py
|   +-- instances.py
|   +-- analysis.py
+-- dashboard/
|   +-- app.py           # Aplicacion Streamlit
|   +-- components.py
+-- utils/
    +-- validators.py
    +-- exporters.py
    +-- helpers.py

```

5.2. Estructuras de Datos Principales

```

1 @dataclass
2 class Item:
3     id: str
4     weight: float
5     value: float
6
7 @dataclass
8 class Bin:
9     id: int
10    capacity: float # Capacidad individual del bin
11    items: List[Item] = field(default_factory=list)
12
13    @property
14    def remaining_capacity(self) -> float:
15        return self.capacity - sum(item.weight for item in self.items)
16
17    @property
18    def total_value(self) -> float:
19        return sum(item.value for item in self.items)
20
21 @dataclass
22 class Problem:
23    items: List[Item]
24    num_bins: int
25    bin_capacities: List[float] # Capacidades individuales por bin
26    name: str = "unnamed"
27
28 @dataclass
29 class Solution:
30    bins: List[Bin]
31    objective: float = 0.0

```

Listing 1: Estructuras de datos principales

6. Resultados Experimentales

6.1. Configuración Experimental

Los experimentos se realizaron con las siguientes configuraciones:

- Instancias: 5 conjuntos de prueba (pequeñas, medianas, grandes, correlacionadas, bimodales)
- Métricas: Valor objetivo, tiempo de ejecución, tasa de factibilidad
- Repeticiones: 10 ejecuciones por algoritmo/instancia
- Límite de tiempo: 60 segundos por ejecución

6.2. Análisis de Escalabilidad

Los algoritmos greedy mantienen tiempos de ejecución sub-segundos incluso para instancias grandes ($n > 100$), mientras que las metaheurísticas requieren ajuste de parámetros para equilibrar calidad y tiempo. Branch and Bound solo es práctico para instancias pequeñas ($n < 20$).

6.3. Análisis Comparativo con Solución Óptima

Para evaluar la calidad de las soluciones heurísticas, se compararon contra las soluciones óptimas obtenidas mediante el algoritmo de fuerza bruta en instancias pequeñas ($n \leq 10$).

6.3.1. Metodología

Se generaron 36 instancias de prueba con las siguientes características:

- Tamaños: $n \in \{6, 8\}$ ítems
- Contenedores: $k \in \{2, 3\}$
- Tipos: uniforme, balance perfecto, capacidad ajustada, valores correlacionados

Para cada instancia se calculó:

1. La solución óptima mediante fuerza bruta
2. La solución de cada heurística
3. El gap de optimalidad: $\text{Gap} = \frac{\text{Heurístico} - \text{Óptimo}}{\text{Óptimo}} \times 100\%$
4. El speedup: $\text{Speedup} = \frac{t_{BF}}{t_{\text{Heurístico}}}$

6.3.2. Resultados

Cuadro 5: Rendimiento comparativo de algoritmos vs. óptimo

Algoritmo	Óptimo (%)	Gap Medio (%)	Gap Máx (%)	Tiempo (ms)	Speedup
SA	83.3	2.1	15.4	12	1.2
GA	91.7	1.3	8.2	320	0.04
TabuSearch	75.0	5.8	45.2	55	0.3
FFD	33.3	85.6	307.8	0.1	15.0
BFD	33.3	85.6	307.8	0.1	15.0
LPT	33.3	85.6	307.8	0.1	15.0
RoundRobin	33.3	85.6	307.8	0.1	15.0

6.3.3. Observaciones

1. **Metaheurísticas vs. Greedy:** Las metaheurísticas (SA, GA, TabuSearch) encuentran el óptimo significativamente más frecuentemente que los algoritmos greedy, aunque a costa de mayor tiempo de ejecución.
2. **Trade-off tiempo-calidad:**
 - GA encuentra el óptimo en 91.7 % de casos pero es 8x más lento que SA
 - FFD/BFD son 15x más rápidos que fuerza bruta pero tienen gaps de hasta 300 %
3. **Instancias con balance perfecto:** Todos los algoritmos encuentran el óptimo cuando existe una partición perfecta (gap = 0).
4. **Instancias difíciles:** Los algoritmos greedy fallan especialmente en instancias con distribución no uniforme de valores.

6.3.4. Comportamiento por Tipo de Instancia

Cuadro 6: Tasa de éxito (encontrar óptimo) por tipo de instancia

Tipo	SA	GA	TabuSearch	FFD	LPT
Balance perfecto	100 %	100 %	100 %	100 %	100 %
Uniforme	80 %	90 %	70 %	10 %	10 %
Correlacionado	85 %	95 %	75 %	25 %	25 %
Capacidad ajustada	70 %	80 %	60 %	20 %	20 %

Estos resultados demuestran que:

- Las metaheurísticas son la mejor opción cuando se requiere alta calidad de solución
- Los algoritmos greedy son adecuados para instancias fáciles o cuando el tiempo es crítico
- El algoritmo genético ofrece el mejor balance entre calidad y robustez

7. Conclusiones

7.1. Resumen

Este proyecto presenta una implementación completa y un análisis exhaustivo del problema de Balanced Multi-Bin Packing with Capacity Constraints. Las principales contribuciones incluyen:

1. Formalización matemática rigurosa del problema como ILP
2. Demostración de NP-hardness mediante reducción desde PARTITION
3. Implementación de 9 algoritmos con diferentes enfoques
4. Framework de benchmarking con análisis estadístico
5. Dashboard interactivo para experimentación

7.2. Trabajo Futuro

Posibles extensiones del trabajo incluyen:

- Implementación de más metaheurísticas (Ant Colony, Particle Swarm)
- Algoritmos híbridos (matheurísticas)
- Variantes multi-objetivo del problema
- Paralelización de algoritmos
- Integración con solvers comerciales (Gurobi, CPLEX)

Referencias

Referencias

- [1] Garey, M.R., & Johnson, D.S. (1979). *Computers and Intractability: A Guide to the Theory of NP-Completeness*. W.H. Freeman.
- [2] Martello, S., & Toth, P. (1990). *Knapsack Problems: Algorithms and Computer Implementations*. John Wiley & Sons.
- [3] Coffman, E.G., Garey, M.R., & Johnson, D.S. (1996). Approximation algorithms for bin packing: A survey. *Approximation Algorithms for NP-hard Problems*, 46-93.
- [4] Kirkpatrick, S., Gelatt, C.D., & Vecchi, M.P. (1983). Optimization by simulated annealing. *Science*, 220(4598), 671-680.
- [5] Glover, F. (1986). Future paths for integer programming and links to artificial intelligence. *Computers & Operations Research*, 13(5), 533-549.
- [6] Goldberg, D.E. (1989). *Genetic Algorithms in Search, Optimization and Machine Learning*. Addison-Wesley.

- [7] Graham, R.L. (1969). Bounds on multiprocessing timing anomalies. *SIAM Journal on Applied Mathematics*, 17(2), 416-429.

A. Manual de Uso

A.1. Instalación

```

1 # Clonar repositorio
2 git clone https://github.com/Pol4720/mulas.git
3 cd mulas
4
5 # Crear entorno virtual
6 python -m venv venv
7 source venv/bin/activate # Linux/Mac
8 venv\Scripts\activate # Windows
9
10 # Instalar dependencias
11 pip install -r requirements.txt

```

A.2. Uso Básico

```

1 from discrete_logistics.core import Problem, Item
2 from discrete_logistics.algorithms import FirstFitDecreasing
3
4 # Crear problema con capacidades individuales por bin
5 items = [
6     Item("i1", weight=10, value=20),
7     Item("i2", weight=15, value=30),
8     Item("i3", weight=8, value=15),
9 ]
10
11 problem = Problem(
12     items=items,
13     num_bins=2,
14     bin_capacities=[20.0, 25.0], # Capacidades diferentes
15     name="example"
16 )
17
18 # Resolver
19 algorithm = FirstFitDecreasing()
20 solution = algorithm.solve(problem)
21
22 # Ver resultado
23 print(f"Objetivo: {solution.objective}")

```

A.3. Dashboard

```

1 # Ejecutar dashboard
2 cd discrete_logistics/dashboard
3 streamlit run app.py

```