

Balanced Multi-Bin Packing with Capacity Constraints

Problema de Transporte Logístico Discreto

Diseño y Análisis de Algoritmos

Proyecto DAA

`discrete_logistics`

5 de diciembre de 2025

Resumen

Este informe presenta un estudio completo del problema de *Balanced Multi-Bin Packing with Capacity Constraints*, un problema de optimización combinatoria NP-hard con aplicaciones en logística y distribución de cargas. Se desarrolla la formalización matemática del problema, se demuestra su complejidad computacional mediante reducción desde 3-PARTITION, y se implementan múltiples enfoques algorítmicos incluyendo algoritmos greedy, programación dinámica, branch and bound, y metaheurísticas (Simulated Annealing, Algoritmos Genéticos, Búsqueda Tabú). Se presenta además un análisis experimental comparativo de los algoritmos implementados.

Índice

1. Introducción

1.1. Motivación

El problema de empaquetamiento balanceado en múltiples contenedores surge en numerosas aplicaciones prácticas de logística y distribución. Considérese el escenario de una empresa de transporte que debe distribuir n paquetes en k vehículos, donde cada vehículo tiene una capacidad máxima de peso y se desea equilibrar la carga de trabajo (medida en valor o tiempo de entrega) entre todos los vehículos.

A diferencia del problema clásico de bin packing que busca minimizar el número de contenedores, nuestro problema tiene un número fijo de contenedores y busca:

1. Respetar las restricciones de capacidad de peso
2. Minimizar el desbalance de valores entre contenedores

1.2. Objetivos del Proyecto

Los objetivos principales de este proyecto son:

- Formalizar matemáticamente el problema
- Demostrar su complejidad computacional (NP-hardness)
- Implementar y analizar múltiples enfoques algorítmicos
- Desarrollar herramientas de visualización y benchmarking
- Crear un dashboard interactivo para experimentación

2. Definición Formal del Problema

2.1. Notación y Definiciones

Definición 2.1 (Ítem). *Un ítem $i \in I$ se caracteriza por un par (w_i, v_i) donde:*

- $w_i \in \mathbb{R}^+$: peso del ítem
- $v_i \in \mathbb{R}^+$: valor del ítem

Definición 2.2 (Contenedor (Bin)). *Un contenedor $j \in \{1, \dots, k\}$ tiene una capacidad máxima $C \in \mathbb{R}^+$.*

Definición 2.3 (Asignación). *Una asignación es una función $\sigma : I \rightarrow \{1, \dots, k\}$ que mapea cada ítem a un contenedor.*

Definición 2.4 (Asignación Factible). *Una asignación σ es factible si y solo si:*

$$\forall j \in \{1, \dots, k\} : \sum_{i: \sigma(i)=j} w_i \leq C$$

2.2. Formulación del Problema

Entrada:

- Conjunto de ítems $I = \{1, 2, \dots, n\}$
- Peso $w_i > 0$ y valor $v_i \geq 0$ para cada ítem $i \in I$
- Número de contenedores $k \in \mathbb{Z}^+$
- Capacidad por contenedor $C > 0$

Variable de Decisión:

$$x_{ij} = \begin{cases} 1 & \text{si el ítem } i \text{ es asignado al contenedor } j \\ 0 & \text{en otro caso} \end{cases}$$

Objetivo: Minimizar el *makespan* (valor máximo entre contenedores):

$$\text{mín } z = \max_{j=1}^k \sum_{i=1}^n v_i \cdot x_{ij}$$

O equivalentemente, minimizar la diferencia máxima:

$$\text{mín} \left(\max_j V_j - \min_j V_j \right)$$

donde $V_j = \sum_{i:\sigma(i)=j} v_i$ es el valor total del contenedor j .

2.3. Formulación como Programa Lineal Entero (ILP)

$$\text{minimizar } z \tag{1}$$

$$\text{sujeto a: } \sum_{j=1}^k x_{ij} = 1 \quad \forall i \in I \tag{2}$$

$$\sum_{i=1}^n w_i \cdot x_{ij} \leq C \quad \forall j = 1, \dots, k \tag{3}$$

$$\sum_{i=1}^n v_i \cdot x_{ij} \leq z \quad \forall j = 1, \dots, k \tag{4}$$

$$x_{ij} \in \{0, 1\} \quad \forall i \in I, j = 1, \dots, k \tag{5}$$

$$z \geq 0 \tag{6}$$

Donde:

- (??): Cada ítem debe asignarse a exactamente un contenedor
- (??): Restricción de capacidad por peso
- (??): Definición del makespan
- (??): Variables binarias de decisión

3. Análisis de Complejidad

3.1. NP-Hardness

Teorema 3.1 (NP-Hardness del Balanced Multi-Bin Packing). *El problema de Balanced Multi-Bin Packing with Capacity Constraints es NP-hard.*

Demostración. Demostraremos mediante reducción polinomial desde 3-PARTITION, un problema conocido por ser fuertemente NP-completo.

Definición de 3-PARTITION: Dados enteros a_1, a_2, \dots, a_{3m} y un valor objetivo B tal que $\sum_{i=1}^{3m} a_i = mB$ y $\frac{B}{4} < a_i < \frac{B}{2}$ para todo i , ¿existe una partición de los elementos en m conjuntos S_1, \dots, S_m tal que cada conjunto tiene exactamente 3 elementos y $\sum_{j \in S_i} a_j = B$ para todo i ?

Construcción de la reducción: Dado una instancia de 3-PARTITION, construimos una instancia de nuestro problema:

- Para cada elemento a_i , creamos un ítem con $w_i = v_i = a_i$
- Establecemos $k = m$ contenedores
- Establecemos capacidad $C = B$

Correctitud:

- Si existe una 3-partición válida, podemos asignar los ítems correspondientes a cada contenedor. El valor total de cada contenedor será exactamente B , por lo que el objetivo (diferencia máxima de valores) será 0.
- Si obtenemos una solución con objetivo 0, significa que todos los contenedores tienen el mismo valor total. Dado que la suma total es mB , cada contenedor debe tener valor B . Las restricciones $\frac{B}{4} < a_i < \frac{B}{2}$ garantizan que cada contenedor debe tener exactamente 3 ítems, constituyendo una 3-partición válida.

La reducción es polinomial ya que solo involucra copiar valores. □

3.2. Complejidad de los Algoritmos Implementados

Cuadro 1: Complejidad temporal y espacial de los algoritmos implementados

Algoritmo	Tiempo	Espacio
First Fit Decreasing (FFD)	$O(n \log n)$	$O(n)$
Best Fit Decreasing (BFD)	$O(n^2)$	$O(n)$
Worst Fit Decreasing (WFD)	$O(n \log n)$	$O(n)$
LPT Balanced	$O(n \log n)$	$O(n)$
Programación Dinámica	$O(n \cdot C^k)$	$O(C^k)$
Branch and Bound	$O(k^n)$ peor caso	$O(n)$
Simulated Annealing	$O(I \cdot n)$	$O(n)$
Genetic Algorithm	$O(G \cdot P \cdot n)$	$O(P \cdot n)$
Tabu Search	$O(I \cdot N)$	$O(n + T)$

Donde:

- n : número de ítems
- k : número de contenedores
- C : capacidad de los contenedores
- I : número de iteraciones
- G : número de generaciones
- P : tamaño de población
- N : tamaño del vecindario
- T : tamaño de la lista tabú

4. Algoritmos Implementados

4.1. Algoritmos Greedy

4.1.1. First Fit Decreasing (FFD)

El algoritmo FFD ordena los ítems por peso decreciente y asigna cada ítem al primer contenedor que tiene capacidad suficiente.

Algorithm 1 First Fit Decreasing

```

1: procedure FFD( $items, k, C$ )
2:    $sorted\_items \leftarrow \text{sort}(items, \text{key} = \text{weight}, \text{desc} = \text{True})$ 
3:    $bins \leftarrow [ ] \times k$ 
4:   for  $item \in sorted\_items$  do
5:     for  $j \leftarrow 1$  to  $k$  do
6:       if  $\text{weight}(bins[j]) + item.\text{weight} \leq C$  then
7:          $bins[j].\text{add}(item)$ 
8:         break
9:       end if
10:    end for
11:  end for
12:  return  $bins$ 
13: end procedure

```

4.1.2. LPT Balanced

El algoritmo Longest Processing Time (LPT) adaptado para balanceo asigna cada ítem al contenedor con menor carga actual.

Algorithm 2 LPT Balanced

```
1: procedure LPT(items, k, C)
2:   sorted_items  $\leftarrow$  sort(items, key = value, desc = True)
3:   bins  $\leftarrow$  [ ]  $\times k$ 
4:   for item  $\in$  sorted_items do
5:      $j^* \leftarrow \arg \min_{j: \text{fits}(j, \text{item})} \text{value}(\text{bins}[j])$ 
6:     bins[ $j^*$ ].add(item)
7:   end for
8:   return bins
9: end procedure
```

4.2. Branch and Bound

El algoritmo de Branch and Bound explora sistemáticamente el espacio de soluciones utilizando cotas para podar ramas no prometedoras.

Algorithm 3 Branch and Bound

```
1: procedure BRANCHANDBOUND(items, k, C)
2:   best  $\leftarrow \infty$ 
3:   best_solution  $\leftarrow$  null
4:   queue  $\leftarrow \{(\emptyset, \text{items})\}$   $\triangleright$  (asignación parcial, ítems restantes)
5:   while queue  $\neq \emptyset$  do
6:     (partial, remaining)  $\leftarrow$  queue.pop()
7:     if remaining =  $\emptyset$  then
8:       obj  $\leftarrow$  objective(partial)
9:       if obj < best then
10:        best  $\leftarrow$  obj
11:        best_solution  $\leftarrow$  partial
12:      end if
13:     else
14:       item  $\leftarrow$  remaining[0]
15:       for  $j \leftarrow 1$  to k do
16:         if fits(partial, j, item) then
17:           new_partial  $\leftarrow$  assign(partial, j, item)
18:           lb  $\leftarrow$  lower_bound(new_partial, remaining[1 :])
19:           if lb < best then  $\triangleright$  Pruning
20:             queue.push((new_partial, remaining[1 :]))
21:           end if
22:         end if
23:       end for
24:     end if
25:   end while
26:   return best_solution
27: end procedure
```

4.3. Metaheurísticas

4.3.1. Simulated Annealing

Algorithm 4 Simulated Annealing

```
1: procedure SA(problem,  $T_0$ ,  $\alpha$ , max_iter)
2:   current  $\leftarrow$  initial_solution(problem)
3:   best  $\leftarrow$  current
4:    $T \leftarrow T_0$ 
5:   for  $i \leftarrow 1$  to max_iter do
6:     neighbor  $\leftarrow$  generate_neighbor(current)
7:      $\Delta \leftarrow f(\textit{neighbor}) - f(\textit{current})$ 
8:     if  $\Delta < 0$  or random()  $< e^{-\Delta/T}$  then
9:       current  $\leftarrow$  neighbor
10:      if  $f(\textit{current}) < f(\textit{best})$  then
11:        best  $\leftarrow$  current
12:      end if
13:    end if
14:     $T \leftarrow \alpha \cdot T$  ▷ Enfriamiento
15:  end for
16:  return best
17: end procedure
```

4.3.2. Algoritmo Genético

Algorithm 5 Algoritmo Genético

```
1: procedure GA(problem, pop_size, generations,  $p_c$ ,  $p_m$ )
2:   population  $\leftarrow$  initialize_population(pop_size)
3:   for  $g \leftarrow 1$  to generations do
4:     fitness  $\leftarrow$  evaluate(population)
5:     new_pop  $\leftarrow \emptyset$ 
6:     while  $|new\_pop| < pop\_size$  do
7:       parent1, parent2  $\leftarrow$  tournament_select(population, fitness)
8:       if random()  $< p_c$  then
9:         child1, child2  $\leftarrow$  crossover(parent1, parent2)
10:      else
11:        child1, child2  $\leftarrow$  parent1, parent2
12:      end if
13:      if random()  $< p_m$  then
14:        child1  $\leftarrow$  mutate(child1)
15:        child2  $\leftarrow$  mutate(child2)
16:      end if
17:      new_pop  $\leftarrow new\_pop \cup \{child_1, child_2\}$ 
18:    end while
19:    population  $\leftarrow new\_pop$ 
20:  end for
21:  return best(population)
22: end procedure
```

5. Estructura del Proyecto

5.1. Arquitectura de Módulos

El proyecto está organizado en los siguientes módulos principales:

```
discrete_logistics/
  core/
    problem.py          # Estructuras de datos
    instance_generator.py
  algorithms/
    base.py             # Clase abstracta Algorithm
    greedy.py           # FFD, BFD, WFD, LPT
    dynamic_programming.py
    branch_and_bound.py
    metaheuristics.py   # SA, GA, Tabu
    approximation.py
  visualizations/
    plots.py            # Gráficos estáticos
    animations.py       # Animaciones Manim/Plotly
    interactive.py      # Componentes interactivos
```



```

theory/
  formalization.py
  complexity.py
  pseudocode.py
benchmarks/
  runner.py
  instances.py
  analysis.py
dashboard/
  app.py          # Aplicación Streamlit
  components.py
utils/
  validators.py
  exporters.py
  helpers.py

```

5.2. Estructuras de Datos Principales

```

1 @dataclass
2 class Item:
3     id: str
4     weight: float
5     value: float
6
7 @dataclass
8 class Bin:
9     capacity: float
10    items: List[Item] = field(default_factory=list)
11
12    @property
13    def remaining_capacity(self) -> float:
14        return self.capacity - sum(item.weight for item in self.items)
15
16    @property
17    def total_value(self) -> float:
18        return sum(item.value for item in self.items)
19
20 @dataclass
21 class Problem:
22     items: List[Item]
23     num_bins: int
24     bin_capacity: float
25     name: str = "unnamed"
26
27 @dataclass
28 class Solution:
29     bins: List[Bin]
30     objective: float = 0.0

```

Listing 1: Estructuras de datos principales

6. Resultados Experimentales

6.1. Configuración Experimental

Los experimentos se realizaron con las siguientes configuraciones:

- Instancias: 5 conjuntos de prueba (pequeñas, medianas, grandes, correlacionadas, bimodales)
- Métricas: Valor objetivo, tiempo de ejecución, tasa de factibilidad
- Repeticiones: 10 ejecuciones por algoritmo/instancia
- Límite de tiempo: 60 segundos por ejecución

6.2. Resultados Comparativos

Cuadro 2: Comparación de algoritmos en instancias medianas ($n=30$, $k=5$)

Algoritmo	Obj. Medio	Tiempo (s)	Factible %
FFD	15.23	0.001	100
BFD	14.87	0.002	100
WFD	12.45	0.001	100
LPT	8.32	0.001	100
Simulated Annealing	5.67	2.34	100
Genetic Algorithm	4.89	5.67	100
Tabu Search	5.12	1.89	100
Branch & Bound	3.45	45.2	85

6.3. Análisis de Escalabilidad

Los algoritmos greedy mantienen tiempos de ejecución sub-segundos incluso para instancias grandes ($n > 100$), mientras que las metaheurísticas requieren ajuste de parámetros para equilibrar calidad y tiempo. Branch and Bound solo es práctico para instancias pequeñas ($n < 20$).

7. Conclusiones

7.1. Resumen

Este proyecto presenta una implementación completa y un análisis exhaustivo del problema de Balanced Multi-Bin Packing with Capacity Constraints. Las principales contribuciones incluyen:

1. Formalización matemática rigurosa del problema como ILP
2. Demostración de NP-hardness mediante reducción desde 3-PARTITION
3. Implementación de 9 algoritmos con diferentes enfoques

4. Framework de benchmarking con análisis estadístico
5. Dashboard interactivo para experimentación

7.2. Trabajo Futuro

Posibles extensiones del trabajo incluyen:

- Implementación de más metaheurísticas (Ant Colony, Particle Swarm)
- Algoritmos híbridos (matheurísticas)
- Variantes multi-objetivo del problema
- Paralelización de algoritmos
- Integración con solvers comerciales (Gurobi, CPLEX)

Referencias

Referencias

- [1] Garey, M.R., & Johnson, D.S. (1979). *Computers and Intractability: A Guide to the Theory of NP-Completeness*. W.H. Freeman.
- [2] Martello, S., & Toth, P. (1990). *Knapsack Problems: Algorithms and Computer Implementations*. John Wiley & Sons.
- [3] Coffman, E.G., Garey, M.R., & Johnson, D.S. (1996). Approximation algorithms for bin packing: A survey. *Approximation Algorithms for NP-hard Problems*, 46-93.
- [4] Kirkpatrick, S., Gelatt, C.D., & Vecchi, M.P. (1983). Optimization by simulated annealing. *Science*, 220(4598), 671-680.
- [5] Glover, F. (1986). Future paths for integer programming and links to artificial intelligence. *Computers & Operations Research*, 13(5), 533-549.
- [6] Goldberg, D.E. (1989). *Genetic Algorithms in Search, Optimization and Machine Learning*. Addison-Wesley.
- [7] Graham, R.L. (1969). Bounds on multiprocessing timing anomalies. *SIAM Journal on Applied Mathematics*, 17(2), 416-429.

A. Manual de Uso

A.1. Instalación

```

1 # Clonar repositorio
2 git clone <repository-url>
3 cd mulas
4
5 # Crear entorno virtual
6 python -m venv venv
7 source venv/bin/activate # Linux/Mac
8 venv\Scripts\activate    # Windows
9
10 # Instalar dependencias
11 pip install -r requirements.txt

```

A.2. Uso Básico

```

1 from discrete_logistics.core import Problem, Item
2 from discrete_logistics.algorithms import FirstFitDecreasing
3
4 # Crear problema
5 items = [
6     Item("i1", weight=10, value=20),
7     Item("i2", weight=15, value=30),
8     Item("i3", weight=8, value=15),
9 ]
10
11 problem = Problem(
12     items=items,
13     num_bins=2,
14     bin_capacity=20,
15     name="example"
16 )
17
18 # Resolver
19 algorithm = FirstFitDecreasing()
20 solution = algorithm.solve(problem)
21
22 # Ver resultado
23 print(f"Objetivo: {solution.objective}")

```

A.3. Dashboard

```

1 # Ejecutar dashboard
2 cd discrete_logistics/dashboard
3 streamlit run app.py

```